GPU 容量规划

1 背景

假设你是学校计算服务中心的运营维护工程师。当前学校准备上线一个同时处理文本和图像请求的 AI 服务。每个请求都会占用一定的 GPU 时间。如果在一分钟内所有请求所需 GPU 时间超过学校计算服务中心的所有服务器能够提供的有效容量，则视作**超载**。请你估算学校的 AI 服务需要配置多少块 GPU，才能有效避免超载。以下是 AI 服务的基本信息。

- 每块 GPU 每分钟理论上提供 60 GPU 秒。为控制排队延迟，只允许按 80% 利用率规划，因此每块 GPU 的**有效容量**为 48 GPU 秒/分钟。
- 若配置 m 块 GPU，一分钟有效总容量为 $48m$ GPU 秒。
- 工作日高峰定义为：工作日 17:00–21:59，见数据文件描述。
- 服务等级目标：工作日高峰一分钟超载概率不超过 1%，即，在一分钟内，如果以 W 表示全部文本与图像请求所需 GPU 时间之和，那么有效总容量需要满足

$$\mathbb{P}(W > 48m) \le 0.01.$$

你需要考虑以下两种情景下的负载情况，并确定 GPU 配置需求。

(1) 根据请求数据，计算满足服务等级目标的**最少配置**；

(2) 考虑模型误差、参数不确定性和突发流量后的**运营建议**。

2 数据文件描述

2.1 分钟请求计数：`request_count.csv`

该文件包含连续 14 天、每分钟一行的请求计数，共 20160 行。

字段	含义
variant	数据版本编号
timestamp	分钟时间戳
day_of_week	星期
day_type	weekday 或 weekend
period	night / morning / daytime / peak / late
text_requests	该分钟文本请求数
image_requests	该分钟图像请求数
total_requests	两类请求数之和

2.2 请求服务时间：service_time.csv

该文件包含 4000 次文本请求和 1600 次图像请求的 GPU 处理时间。

字段	含义
variant	数据版本编号
request_id	服务时间样本编号
request_type	text 或 image
gpu_seconds	该请求占用的 GPU 秒数
cold_start	是否发生冷启动：1 表示是，0 表示否

3 符号规定

在一个给定分钟内，考虑以下随机变量

- N_T：文本请求数；N_I：图像请求数；
- $T_1, T_2, \ldots$：各文本请求的 GPU 时间；
- $I_1, I_2, \ldots$：各图像请求的 GPU 时间；
- W：一分钟总 GPU 工作量。

因此，我们有

$$W = \sum_{j=1}^{N_T} T_j + \sum_{k=1}^{N_I} I_k.$$

4 探究问题

第 1 步：请求数量建模

(1) 绘制不同时段的两种请求数量的箱线图。请问：能否只研究工作日高峰的请求数量?

(2) 对工作日高峰的 N_T 和 N_I 分别建立泊松分布模型，参数分别为 λ_T 和 λ_I。估计参数 λ_T 和 λ_I 并给出 95% 置信区间。

(3) 至少使用一种方法检验泊松假设，例如 χ^2 拟合检验。若拒绝模型，需要指出不符合之处，并提出一种可执行的修正。

(4) 计算 N_T 与 N_I 的相关系数，判断两类请求是否可能受到共同流量冲击，即大量多模态请求的冲击。

第 2 步：请求处理时间建模

(1) 分别研究文本请求与图像请求的 GPU 处理时间：报告样本量、均值、标准差、中位数、95% 与 99% 分位数，并画出直方图。

(2) 利用冷启动数据，估计冷启动概率及冷启动前后的平均处理时间；使用全概率公式解释冷启动对总体均值和右尾的贡献。

(3) 为两类请求的处理时间建立概率模型，既可以是参数分布，也可以是经验分布。

(4) 分别记 T 和 I 为单一文本请求需要的 GPU 时间以及单一图像请求需要的 GPU 时间。估计以下参数

$$\mu_T = \mathbb{E}(T), \quad \sigma_T^2 = \mathrm{Var}(T), \quad \mu_I = \mathbb{E}(I), \quad \sigma_I^2 = \mathrm{Var}(I),$$

以及二阶矩 $\mathbb{E}(T^2)$ 以及 $\mathbb{E}(I^2)$。

第 3 步：一分钟总负载

(1) 假设 N_T 和 N_I 相互独立，对于工作日高峰的情况，估计一分钟总工作量 W 的均值、标准差，以及两类请求对均值和方差的贡献。

(2) 如果假设 N_T 和 N_I 不相互独立，讨论上述估计是否还有效。

第 4 步：中心极限定理近似 W

(1) 根据中心极限定理，如果用正态分布对 W 建模，对若干 m 计算 $\mathbb{P}(W > 48m)$。

(2) 找出正态分布近似下，使超载概率首次不超过 1% 的最小 m。

(3) 解释使用中心极限定理的理由和风险：随机项数量是否足够？图像请求是否过少？服务时间长尾是否会影响右尾近似？

第 5 步：蒙特卡洛模拟检验

(1) 设计模拟算法测试上一步中得到最小 m 是否能完成服务等级目标，请确保重复次数不少于 50000 次。

(2) 正态分布近似估计的最小 GPU 配置是否通过了模拟检验。若没有通过，请分析造成差异的原因。

第 6 步：压力测试

(1) **情景 A**：三个月后，文本与图像请求的到达规模均增加 30%，服务时间分布不变。重新计算最少 GPU 数量。

(2) **情景 B**：总请求数过程保持当前高峰水平，但每个请求为图像请求的概率变为 35%。重新计算最少 GPU 数量。

第 7 步：决策备忘录

请你给计算服务平台的负责人写一份不超过一页的决策备忘录，包含以下内容：

- 当前满足服务等级目标的最少配置是多少？你实际建议部署多少？
- 三个月后应扩容到多少？
- 图像占比升至 35% 时，单纯增加 GPU 是否仍是合理方案？
- 超载风险主要来自平均流量、到达波动、图像处理时间还是冷启动？
- 平台应监测哪些指标？达到什么阈值时触发扩容？
- 结论依赖哪些关键假设？哪一个假设最值得继续收集数据？